

Análisis de Usuarios de Streaming

Proyecto Integrador – Minería de Datos I

Autor: Enzo Pazzelli **Comisión:** Sede Nodo - Turno Tarde **Fecha:** 28/6/2026

Repositorio: [link GitHub](#) **Aplicación:** [link Streamlit Cloud](#)

1. Contexto y objetivo

El proyecto parte de un conjunto de datos de usuarios de una plataforma de streaming, entregado en bruto y con problemas de calidad. El objetivo fue preparar los datos para su análisis, explorarlos para responder preguntas sobre el comportamiento de consumo, y aplicar PCA para evaluar si las variables numéricas podían resumirse en pocas dimensiones. Los resultados se comunican además mediante una aplicación interactiva en Streamlit.

2. Dataset y calidad inicial

El archivo original (streaming_users_dirty.json) contenía 8.160 registros y 8 variables: identificador, edad, plan de suscripción, minutos vistos por mes, país, género favorito, fecha de último login y cantidad de tickets de soporte. El conjunto presentaba problemas de calidad significativos: filas duplicadas, categorías escritas de múltiples formas (mayúsculas, idiomas, abreviaturas), valores imposibles (edades negativas o mayores a 100, minutos negativos y valores centinela), datos faltantes y fechas en formatos mezclados.

3. Decisiones de limpieza

El proceso de limpieza se documentó paso a paso en un log de pipeline. Las decisiones principales fueron:

- **Duplicados:** se eliminaron 126 filas exactas y se unificaron 34 identificadores repetidos, conservando en cada caso el registro más completo.
- **Normalización:** las variables categóricas se llevaron a una forma canónica única mediante diccionarios de mapeo.
- **Valores imposibles:** se marcaron como faltantes en lugar de eliminar la fila. Para los minutos vistos se aplicó un umbral físico (43.200 minutos, el máximo de un mes), que captura los valores centinela.
- **Faltantes:** las variables numéricas se imputaron con la mediana (robusta a la asimetría) y el género ausente con la categoría "Desconocido". Las fechas faltantes no se imputaron.
- **Fechas:** se parsearon los tres formatos presentes y se descartaron las fechas futuras, imposibles para un último acceso.

El proceso resultó en un dataset final de 8.000 usuarios con una retención estructural del 98,04% (de 8.160 registros iniciales). El detalle paso a paso queda registrado en logs/pipeline_log.csv.

Etapas	Filas	Retención
Dataset original	8.160	100,00%

Etapa	Filas	Retención
Tras eliminar duplicados	8.000	98,04%
Dataset final limpio	8.000	98,04%

4. Hallazgos del análisis exploratorio

El análisis exploratorio reveló una única relación marcada y ausencia de asociación en el resto de las variables:

- **El consumo aumenta con el plan contratado.** La mediana de minutos vistos por mes pasa de 558 (Básico) a 833 (Estándar) a 1.081 (Premium). Es la relación más fuerte del conjunto.
- **La edad no se asocia con el consumo:** correlación ≈ 0 .
- **La inactividad (días desde el último login)** tampoco se asocia con el consumo.

5. Reducción de dimensionalidad (PCA)

Se aplicó PCA sobre las cuatro variables numéricas, previamente estandarizadas con StandardScaler (paso obligatorio, dado que las varianzas sin escalar diferían en un factor del orden de 10^6). Las cuatro componentes explican una proporción casi idéntica de la varianza (aproximadamente 25% cada una), lo que indica que las variables son estadísticamente independientes y el PCA no logra resumirlas. Al proyectar los usuarios sobre las dos primeras componentes y colorear por plan, no se observan grupos separables. El PCA confirma así la ausencia de estructura latente.

6. Conclusiones y limitaciones

El comportamiento de los usuarios está determinado casi exclusivamente por el plan contratado: los usuarios Premium consumen cerca del doble que los de plan Básico. El resto de las variables —edad, inactividad y tickets— no presentan asociación con el consumo ni entre sí, hallazgo que el PCA reafirma. Como recomendación de negocio, no resultaría efectivo segmentar campañas por edad; el nivel de consumo es el verdadero diferenciador entre planes.

Entre las limitaciones, la ausencia casi total de correlaciones sugiere que el dataset podría ser de naturaleza sintética, lo que limita la generalización de las conclusiones. Además, las imputaciones por mediana tienden a aplanar diferencias finas, y 472 usuarios sin fecha de login fueron excluidos del análisis de componentes principales.

El proceso completo está en los notebooks del repositorio y el análisis interactivo, en la aplicación de Streamlit.